20251216_Statistik_WIN2

Aufgabe 1: Pearson-Korrelation – Werbebudget und Umsatz

Ein Online-Shop betrachtet 5 Monate.
Es seien (in 100-€ bzw. 1000-€ Einheiten):

- x: Werbebudget in **Hundert €**
- y: Monatsumsatz in **Tausend €**

Daten:

Monat	1	2	3	4	5
x	1	2	3	4	5
y	3	4	6	8	9

1. Berechne die Mittelwerte $\bar{x}$ und $\bar{y}$.
2. Berechne den Pearson-Korrelationskoeffizienten r_{XY}.
3. Interpretiere Betrag und Vorzeichen von r_{XY} im Kontext.

Aufgabe 2: Negative Korrelation – Testaufwand und Fehlerquote

Ein Software-Team misst an 5 Modulen:

- x: Testaufwand (Personentage)
- y: Anzahl Fehler pro 1000 Zeilen Code (KLOC) nach Release

Daten:

Modul	1	2	3	4	5
x	1	2	3	4	5
y	16	12	10	8	7

1. Berechne $\bar{x}$ und $\bar{y}$.
2. Berechne den Korrelationskoeffizienten r_{XY}.
3. Interpretiere das Ergebnis.

Aufgabe 3: Korrelationsmatrix – Online-Marketing-Kennzahlen

Eine Marketing-Abteilung betrachtet 4 Kampagnen.
Für jede Kampagne $i = 1, \ldots, 4$:

- x_1: Werbebudget (Tsd. €)
- x_2: Klicks auf die Anzeigen (Tsd.)
- x_3: Umsatz (Tsd. €)

Daten:

Kampagne i	1	2	3	4
x_1 (Budget)	1	2	3	4
x_2 (Klicks)	5	9	12	15
x_3 (Umsatz)	8	14	20	23

1. Berechne die Mittelwerte $\bar{x}_1, \bar{x}_2, \bar{x}_3$.
2. Berechne die Korrelationskoeffizienten r_{12}, r_{13}, r_{23}.
3. Stelle die **Korrelationsmatrix** auf.
4. Interpretiere kurz die drei Zusammenhänge.

Aufgabe 4: Interpretation einer Korrelationsmatrix – KPI-Auswahl für ein Dashboard

Ein Controlling-Team hat aus historischen Daten folgende **Korrelationsmatrix** (Pearson) ermittelt:

Variablen:

- U: Monatsumsatz (Tsd. €)
- B: Werbebudget (Tsd. €)
- V: Besuchszahl der Website (Tsd.)
- P: durchschnittlicher Produktpreis (in €)

Korrelationsmatrix:

$$R = \begin{pmatrix} & U & B & V & P \\ U & 1{,}00 & 0{,}85 & 0{,}80 & -0{,}20 \\ B & 0{,}85 & 1{,}00 & 0{,}90 & 0{,}10 \\ V & 0{,}80 & 0{,}90 & 1{,}00 & 0{,}05 \\ P & -0{,}20 & 0{,}10 & 0{,}05 & 1{,}00 \end{pmatrix}$$

1. Welches Merkmal steht am stärksten mit dem Umsatz U in linearem Zusammenhang?
2. Welche beiden Merkmale sind untereinander am stärksten korreliert (unabhängig von U)?
3. Welche Probleme können bei der Verwendung von B und V gleichzeitig als Erklärungsvariablen in einem Regressionsmodell für U auftreten?
4. Warum kann man aus den Korrelationen **nicht** direkt auf Kausalität schließen?

Aufgabe 5: Einfluss von Ausreißern auf die Korrelation – Bug-Analyse

Für 5 Releases einer Software wurden gemessen:

- x: Anzahl neuer Features im Release
- y: Anzahl Bugs, die in der ersten Woche gemeldet wurden

Daten (Releases 1–5):

Release	1	2	3	4	5
x	1	2	3	4	5
y	2	4	6	8	10

1. Beschreibe ohne Rechnung die lineare Beziehung zwischen x und y. Welchen Korrelationskoeffizienten erwartest du?
2. Nun kommt Release 6 mit ungewöhnlichem Verlauf (Notfallrelease ohne Tests):

$$x_6 = 6, \quad y_6 = 0$$

   Berechne den Korrelationskoeffizienten mit **allen 6** Releases.
3. Vergleiche das Ergebnis und interpretiere den Einfluss des Ausreißers.

$$\boxed{r_{xy} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2}\sqrt{\sum (y_i - \bar{y})^2}}}$$

1.

$$\bar{x} = \frac{\sum x_i}{n} = \frac{15}{5} = 3$$

$$\bar{y} = \frac{\sum y_i}{n} = \frac{30}{5} = 6$$

$$r_{xy} = \frac{(1-3)(3-6) + (2-3)(4-6) + (3-3)(6-6) + (4-3)(8-6) + (5-3)(9-6)}{\sqrt{(1-3)^2 + (2-3)^2 + (4-3)^2 + (5-3)^2}\sqrt{(3-6)^2 + (4-6)^2 + (8-6)^2 + (9-6)^2}} =$$

$= 0{,}993 > 0$: sehr starker positiver linearer Zusammenhang.

2.

$$\bar{x} = \frac{\sum x_i}{n} = 3$$

$$\bar{y} = \frac{\sum y_i}{n} = \frac{53}{5} = 10{,}6$$

$$r_{xy} = \frac{(1-3)(16-10'6)+(2-3)(12-10'6)+(4-3)(8-10'6)+(5-3)(7-10'6)}{\sqrt{(1-3)^2+(2-3)^2+(4-3)^2+(5-3)^2}\sqrt{(16-10'6)^2+(12-10'6)^2+(10-10'6)^2+(8-10'6)^2+(7-10'6)^2}}$$

$= -0'97$: zeer starker negatieve lineaire Zusammenhang.

3. $$R = \begin{bmatrix} 1 & r_{12} & r_{13} \\ r_{12} & 1 & r_{23} \\ r_{13} & r_{23} & 1 \end{bmatrix}$$

$\bar{x}_1 = \frac{1+2+3+4}{4} = 2'5$ $\quad \bar{x}_2 = \frac{5+9+12+15}{4} = 10'25$ $\quad \bar{x}_3 = \frac{8+14+20+23}{4} = 16'25$

$$r_{12} = \frac{(1-2'5)(5-10'25)+(2-2'5)(9-10'25)+(3-2'5)(12-10'25)+(4-2'5)(15-10'25)}{\sqrt{(1-2'5)^2+(2-2'5)^2+(3-2'5)^2+(4-2'5)^2}\sqrt{(5-10'25)^2+(9-10'25)^2+(12-10'25)^2+(15-10'25)^2}}$$

$= 0'998$

$$r_{13} = \frac{(1-2'5)(8-16'25)+(2-2'5)(14-16'25)+(3-2'5)(20-16'25)+(4-2'5)(23-16'25)}{\sqrt{(1-2'5)^2+(2-2'5)^2+(3-2'5)^2+(4-2'5)^2}\sqrt{(8-16'25)^2+(14-16'25)^2+(20-16'25)^2+(23-16'25)^2}}$$

$= 0'99$

$$r_{23} = \frac{(5-10'25)(8-16'25)+(9-10'25)(14-16'25)+(12-10'25)(20-16'25)+(15-10'25)(23-16'25)}{\sqrt{(5-10'25)^2+(9-10'25)^2+(12-10'25)^2+(15-10'25)^2}\sqrt{(8-16'25)^2+(14-16'25)^2+(20-16'25)^2+(23-16'25)^2}}$$

$= 0'995$

$$\mathcal{R} = \begin{bmatrix} 1 & 0'998 & 0'99 \\ 0'998 & 1 & 0'995 \\ 0'99 & 0'995 & 1 \end{bmatrix}$$

4.

$$\begin{array}{cc} & \begin{array}{cccc} U & B & V & P \end{array} \\ \mathcal{R} = & \begin{bmatrix} 1 & 0'85 & 0'8 & -0'2 \\ 0'85 & 1 & 0'9 & 0'1 \\ 0'8 & 0'9 & 1 & 0'05 \\ -0'2 & 0'1 & 0'05 & 1 \end{bmatrix} \end{array}$$

$|r_{U,B}| = 0'85 > |r_{U,V}|$ → Werbebudget B ist am
$> |r_{U,P}|$ stärksten mit U korreliert.

$|r_{B,V}| = 0'9 > |r_{B,P}| = 0'1$ → Zw. B & V besteht der
$> |r_{V,P}| = 0'05$ stärkste Zusammenhang

· B & V sind mit $r_{B,V} = 0'90$ sehr stark korreliert.
· In einer multiplen linearen Regression $U \sim B + V$ führt das zu Multikolinearität, aufgrund der hohen Korrelation zw. B & V.

$U = \alpha_1 B + \alpha_2 V$ ↯

B & V $r_{B,V} = 0'9$

· Warum ist Korrelation keine Kausalität?
Eine hohe Korrelation (z.B. zw. B & U) bedeutet nur:
„Wenn B hoch ist, ist U tendenziell auch hoch"

aber nicht, dass B die URSACHE für U ist.

$$\boxed{\text{Korrelation zeigt linearen Zusammenhang, aber keine Kausalrichtung.}}$$

5. Wir sehen $y = 2x \longrightarrow r_{xy} = 1$ (für Releases 1-5)

$$\bar{x} = \frac{1+2+3+4+5+6}{6} = 3{,}5$$

$$\bar{y} = \frac{2+4+6+8+10+0}{6} = 5$$

$$r_{xy} = \frac{(1-3{,}5)(2-5)(2-3{,}5)(4-5)+(3-3{,}5)(6-5)+(4-3{,}5)(8-5)+(5-3{,}5)(10-5)+(6-3{,}5)(0-5)}{\sqrt{(1-3{,}5)^2+(2-3{,}5)^2+(3-3{,}5)^2+(4-3{,}5)^2+(5-3{,}5)^2+(6-3{,}5)^2} \cdot \sqrt{(2-5)^2+(4-5)^2+(6-5)^2+(8-5)^2+(10-5)^2+(0-5)^2}}$$

$$= 0{,}14$$

- Ein einziger Ausreißer zerstört den nahezu perfekten linearen Zusammenhang in der Korrelation.

$$\boxed{\text{Pearson-Korrelation ist sehr empfindlich gegenüber Ausreißern.}}$$