20251218_Statistik_WIN2

Aufgabe 1: Kovarianzmatrix und PCA – Web-Analytics-KPIs

Ein Online-Shop betrachtet 3 KPIs pro Besuch:

- X_1: Seitenaufrufe pro Besuch
- X_2: Produktklicks pro Besuch
- X_3: Verweildauer in Minuten

Die (bereits berechnete) **Kovarianzmatrix** aus vielen Besuchen lautet:

$$S = \begin{pmatrix} 4 & 3 & 0 \\ 3 & 4 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

1. Bestimme die Eigenwerte und Eigenvektoren von S.
2. Sortiere die Hauptkomponenten nach abnehmender Varianz und berechne den prozentualen Varianzanteil jeder Komponente.
3. Interpretiere die erste und zweite Hauptkomponente inhaltlich.

Aufgabe 2: PCA auf Korrelationsmatrix – drei Marketing-Variablen

Drei standardisierte Marketing-Variablen (Mittelwert 0, Varianz 1):

- X_1: Impressionen (Anzahl eingeblendeter Anzeigen)
- X_2: Klicks
- X_3: Conversions

Die **Korrelationsmatrix** lautet:

$$R = \begin{pmatrix} 1 & 0{,}8 & 0 \\ 0{,}8 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

1. Führe eine PCA basierend auf R durch: bestimme Eigenwerte und Eigenvektoren.
2. Berechne den Varianzanteil der ersten Hauptkomponente.
3. Interpretiere die erste Hauptkomponente inhaltlich.

Aufgabe 3: PCA aus Rohdaten – drei stark korrelierte Server-Metriken

Ein Team beobachtet 3 Kennzahlen (pro Stunde):

- X_1: CPU-Auslastung (in normierter Skala)
- X_2: RAM-Auslastung
- X_3: Disk-IO-Auslastung

Für 4 Stunden werden folgende Werte gemessen:

Stunde i	1	2	3	4
X_1	1	2	3	4
X_2	1	2	3	4
X_3	1	2	3	4

1. Berechne die Mittelwerte $\bar{x}_1, \bar{x}_2, \bar{x}_3$.
2. Berechne die zentrierten Daten $\tilde{x}_{ij}$.
3. Bestimme die Kovarianzmatrix S (mit Faktor $1/(n-1)$).
4. Finde die Eigenwerte und Eigenvektoren von S.
5. Wie viele Hauptkomponenten braucht man, um **100 %** der Varianz zu erklären? Begründe.

Aufgabe 4: Scores in Hauptkomponenten – Nutzerprofil verdichten

Für drei standardisierte User-Features:

- X_1: Anzahl Logins pro Woche (standardisiert)
- X_2: Anzahl Sitzungen pro Woche (standardisiert)
- X_3: durchschnittliche Sitzungsdauer (standardisiert)

wurde eine PCA durchgeführt. Es ergaben sich (normierte) Eigenvektoren:

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix}, \quad \mathbf{v}_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

Ein bestimmter User hat nach Standardisierung die Werte (Zentrierung und Skalierung schon erfolgt):

$$\tilde{\mathbf{x}} = \begin{pmatrix} \tilde{x}_1 \\ \tilde{x}_2 \\ \tilde{x}_3 \end{pmatrix} = \begin{pmatrix} 1{,}0 \\ 0{,}0 \\ -0{,}5 \end{pmatrix}$$

1. Berechne die Scores z_1, z_2, z_3 dieses Users in den drei Hauptkomponenten (Projektion von $\tilde{\mathbf{x}}$ auf $\mathbf{v}_k$).
2. Interpretiere das Nutzerverhalten anhand von z_1, z_2, z_3.

Aufgabe 5: PCA als Konjunkturindex – drei makroökonomische Variablen

Für die Konjunkturanalyse eines Landes werden drei standardisierte Zeitreihen betrachtet:

- X_1: reales BIP-Wachstum (hoch in Boomphasen)
- X_2: Wachstum der Industrieproduktion
- X_3: Arbeitslosenquote (hoch in Krisen, niedrig in Booms)

Die geschätzte **Kovarianzmatrix** (in geeigneten Einheiten) zwischen diesen standardisierten Variablen lautet:

$$S = \begin{pmatrix} 2 & 1 & -1 \\ 1 & 2 & -1 \\ -1 & -1 & 2 \end{pmatrix}$$

1. Bestimme die Eigenwerte und Eigenvektoren von S. (Nutze die Symmetrie und rate sinnvolle Richtungen.)
2. Welche Hauptkomponente würdest du als **Konjunkturindex** verwenden und warum?
3. Wie hoch ist der Varianzanteil dieser Komponente an der Gesamtvarianz?

1. $S = \begin{bmatrix} 4 & 3 & 0 \\ 3 & 4 & 0 \\ 0 & 0 & 1 \end{bmatrix}$ $\quad \det[S - \lambda I] = 0 \rightarrow \det\begin{bmatrix} 4-\lambda & 3 & 0 \\ 3 & 4-\lambda & 0 \\ 0 & 0 & 1-\lambda \end{bmatrix} = 0$

$\rightarrow (4-\lambda)(4-\lambda)(1-\lambda) - 3^2(1-\lambda) = 0 \rightarrow (1-\lambda)\left[(4-\lambda)^2 - 9\right] = 0$

$\lambda_3 = 1$; $(4-\lambda)^2 - 9 = 0 \rightarrow \lambda^2 - 8\lambda + 7 = 0 \rightarrow \lambda = \frac{8 \pm \sqrt{64-28}}{2} = \begin{cases} \lambda_1 = 7 \\ \lambda_2 = 1 \end{cases}$

- $A = \begin{bmatrix} 4 & 3 \\ 3 & 4 \end{bmatrix} \rightarrow \lambda_1 = 7 \rightarrow A\vec{v}_1 = \lambda_1 \vec{v}_1 \rightarrow \begin{bmatrix} 4-7 & 3 \\ 3 & 4-7 \end{bmatrix}\begin{bmatrix} v_{11} \\ v_{12} \end{bmatrix} = 0$

$\left.\begin{array}{l} -3v_{11} + 3v_{12} = 0 \rightarrow v_{11} = v_{12} = 1 \\ v_{13} = 0 \end{array}\right\} \vec{v}_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}$

- $A = \begin{bmatrix} 4 & 3 \\ 3 & 4 \end{bmatrix} \rightarrow \lambda_2 = 1 \rightarrow A\vec{v}_2 = \lambda_2 \vec{v}_2 \rightarrow \begin{bmatrix} 4-1 & 3 \\ 3 & 4-1 \end{bmatrix}\begin{bmatrix} v_{21} \\ v_{22} \end{bmatrix} = 0$

$\left.\begin{array}{l} 3v_{21} + 3v_{22} = 0 \rightarrow v_{21} = -v_{22} = 1 \\ v_{23} = 0 \end{array}\right\} \vec{v}_2 = \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}$

· $\lambda_3 = 1$: Varianz $= 1$ $\longrightarrow$ $\vec{v}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$

Keine Kovarianz

$$\text{Anteil}_1 = \frac{1}{1+1+1} = 77'8\% \qquad \text{Anteil}_2 = \frac{1}{1+1+1} = 11'1\% = \text{Anteil}_3$$

Interpretation: PC1: Eigenvektor $\vec{v}_1 : \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}$; beide KPIs $[x_1 \,\&\, x_2]$ gehen gleich gerichtet ein.

PC1 misst eine Art „Gesamtaktivität auf der Seite". (viel surfen & viel klicken)

PC2: Eigenvektor $\vec{v}_2 : \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}$; Differenz zw. $[x_1 \,\&\, x_2]$

PC2 misst ob Nutzer viel surfen aber weniger klicken.

PC3: Eigenvektor $\vec{v}_3 \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$; reine Verweildauer

Unabhängig von x_1 & x_2.

Praktisch PC1 ist ein „Engagement Index" auf der Seite.

2.

$$R = \begin{bmatrix} 1 & 0'8 & 0 \\ 0'8 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$A = \begin{bmatrix} 1 & 0'8 \\ 0'8 & 1 \end{bmatrix} \longrightarrow \det\left[A - \lambda I\right] = 0 \longrightarrow \det\begin{bmatrix} 1-\lambda & 0'8 \\ 0'8 & 1-\lambda \end{bmatrix} = 0$$

$$\longrightarrow (1-\lambda)^2 - 0'8^2 = 0 \longrightarrow \lambda^2 - 2\lambda + 0'36 = 0 \longrightarrow \lambda = \frac{2 \pm \sqrt{4 - 4 \cdot 0'36}}{2} = \begin{cases} \lambda_1 = 1'8 \\ \lambda_2 = 0'2 \end{cases}$$

$$\lambda_3 = 1 \rightarrow \vec{v_3} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

$$\lambda_1 = 1'8 \rightarrow [A - \lambda I]\begin{bmatrix} \vec{v_1} \end{bmatrix} = \vec{0} \longrightarrow \begin{bmatrix} 1-1'8 & 0'8 \\ 0'8 & 1-1'8 \end{bmatrix}\begin{bmatrix} v_{11} \\ v_{12} \end{bmatrix} = \vec{0}$$

$$\begin{bmatrix} -0'8 & 0'8 \\ 0'8 & -0'8 \end{bmatrix}\begin{bmatrix} v_{11} \\ v_{12} \end{bmatrix} = \vec{0} \rightarrow v_{11} = v_{12} = 1 \longrightarrow \vec{v_1} = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}$$

$$\lambda_2 = 0'2 \longrightarrow \dots \longrightarrow \vec{v_2} = \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}$$

$$\text{Anteil}_1 = \frac{1'8}{1'8 + 0'2 + 1} = 0'6 \qquad \text{Anteil}_2 = \frac{0'2}{1'8 + 0'2 + 1} = 0'067$$

PC1 erklärt 60% der Variabilität.

Interpretation: $\vec{v_1} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}$ PC1 ist ungefähr der Mittelwert zw. Impressionen & Klicks.

· Einen hohen Score bei PC1 in einer Kampagne bedeutet viele Impressionen (Reichweite) & viele Klicks (Engagement).

---

3. $\bar{x}_1 = \bar{x}_2 = \bar{x}_3 = 2'5$

$x_i^* = x_i - 2'5 \longrightarrow$

	1	2	3	4
x_{i1}^*	$-1'5$	$-0'5$	$0'5$	$1'5$
x_{i2}^*	...			
x_{i3}^*	...			

$$\left.\begin{aligned} s_{11} = s_{22} = s_{33} &= \frac{1}{3}\sum (x_{i1}^*)^2 = \frac{5}{3} \\ s_{12} = s_{13} = s_{23} &= \frac{1}{3}\sum x_{i2}^* x_{i1}^* = \frac{5}{3} \end{aligned}\right\} S = \frac{5}{3}\begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

$$\vec{v_1} = \vec{v_2} = \vec{v_3} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \qquad \lambda_1 = 5 \qquad \lambda_2 = 0 \qquad \lambda_3 = 0$$

Nur eine HK notwendig, weil die erste HK1 (λ_1) erklärt 100% der Variabilität.

---

4. $\vec{v_1} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} \quad \vec{v_2} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix} \quad \vec{v_3} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \quad \vec{\hat{x}} = \begin{bmatrix} 1 \\ 0 \\ -0{,}5 \end{bmatrix}$

$$z_1 = \vec{\hat{x}}^T \cdot \vec{v_1} = \begin{bmatrix} 1 & 0 & -0{,}5 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} \cdot \frac{1}{\sqrt{2}} = \begin{bmatrix} 1.1 + 0.1 - 0{,}5 \cdot 0 \end{bmatrix} \cdot \frac{1}{\sqrt{2}} = 0{,}707$$

$$z_2 = \vec{\hat{x}}^T \cdot \vec{v_2} = \begin{bmatrix} 1 & 0 & -0{,}5 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix} \cdot \frac{1}{\sqrt{2}} = \begin{bmatrix} 1.1 + 0.1 - 0{,}5 \cdot 0 \end{bmatrix} \cdot \frac{1}{\sqrt{2}} = 0{,}707$$

$$z_3 = \vec{\hat{x}}^T \cdot \vec{v_3} = \begin{bmatrix} 1 & 0 & -0{,}5 \end{bmatrix} \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 1.0 + 0.0 - 0{,}5 \cdot 1 \end{bmatrix} = -0{,}5$$

Interpretation: $PC_1 [x_1 + x_2]$ → allgemeine Aktivität $z_1 \approx 0{,}71 > 0$
Nutzer überdurch. aktiv.

$PC_2 [x_1 - x_2]$ – unterschied logins & Sitzungen
$z_2 \approx 0{,}71 > 0$
Tendenz mehr logins als Sitzungen

$PC_3 [x_3]$ – $z_3 = -0{,}5$
Nutzer unterdurchsch. aktiv.
(kürzere Sessions).

Nutzer, der sehr häufig (viele logins) und oft kurz reinkommt, aber nicht besonders lange bleibt.

---

5. $S = \begin{bmatrix} 2 & 1 & -1 \\ 1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix}$

$$\det[S - \lambda I] = 0 \rightarrow \det\begin{bmatrix} 2-\lambda & 1 & -1 \\ 1 & 2-\lambda & -1 \\ -1 & -1 & 2-\lambda \end{bmatrix} = 0 \rightarrow$$

$$(2-\lambda)^3 + 1 + 1 - (2-\lambda) - (2-\lambda) - (2-\lambda) = 0$$

$$(2-\lambda)^3 - 3(2-\lambda) + 2 = 0$$

$$(2-\lambda)\left[(2-\lambda)^2 - 3\right] + 2 = 0 \rightarrow (2-\lambda)\left[\lambda^2 - 4\lambda + 1\right] + 2 = 0$$

$$\left.\lambda = \frac{4 \pm \sqrt{16-4}}{2} = \frac{4 \pm \sqrt{12}}{2}\right\} \rightarrow (2-\lambda)\left[(\lambda - 3'73)(\lambda - 0'27)\right] + 2 = 0$$

...

a) Erste Vermutung: „Boom-Richtung"

x_1 & x_2 hoch

x_3 niedrig

Richtung ist etwa $\vec{v_1} = \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix}$

Wir prüfen ob dies ein Eigenvektor ist:

$$S \cdot \vec{v_1} = \begin{bmatrix} 2 & 1 & -1 \\ 1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 2\cdot 1 + 1\cdot 1 + (-1)(-1) \\ 1\cdot 1 + 2\cdot 1 + (-1)(-1) \\ -1\cdot 1 + (-1)\cdot 1 + 2\cdot(-1) \end{bmatrix} = 4 \underbrace{\begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix}}_{\vec{v_1}}$$

$\lambda_1 = 4 \qquad \vec{v_1} = \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix}$

b) Zweite Vermutung: Differenz zw. BIP & Industrieprod.

$$\vec{v_2} = \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}$$

$$S\vec{v_2} = \begin{bmatrix} 2 & 1 & -1 \\ 1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix} = \dots = 1 \cdot \underbrace{\begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}}_{\vec{v_2}}$$

c) Die Spur von S ist die Summe der Eigenwerte

$$S = \begin{bmatrix} 2 & 1 & -1 \\ 1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix} \qquad \text{spur}(S) = 2+2+2 = \underset{4}{\lambda_1} + \underset{1}{\lambda_2} + \lambda_3 \rightarrow \lambda_3 = 1$$

$$\rightarrow \lambda_3 = 1 \rightarrow \vec{v_3} = \begin{bmatrix} 1 \\ 1 \\ 2 \end{bmatrix}$$

Wahl eines Konjunkturindex:

Die erste HK (größter Eigenwert) beschreibt die Richtung maximaler Varianz.

$\lambda_1 = 4$; $\vec{v_1} = \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix}$: $\begin{cases} \text{Positiv mit } x_1 : \text{BIP-Wachstum} \\ \text{" " } x_2 : \text{Industrieprod.} \\ \text{Negativ " } x_3 : \text{Arbeitslosenquote} \end{cases}$

Im Boom-Phasen: x_1, x_2 sind groß, x_3 klein $\rightarrow$ hoher PC1 score

In Krisen: x_1, x_2 sind klein, x_3 groß $\rightarrow$ negativer PC1 score

$\boxed{\text{PC1 ist ein sinnvoller Konjunkturindex.}}$