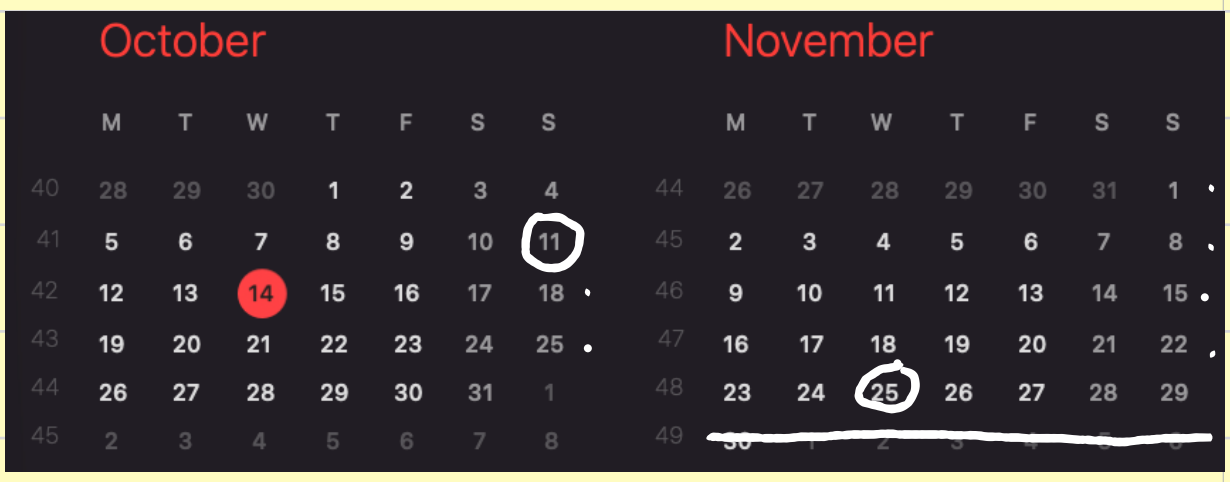
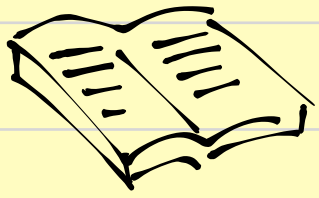
20261014_AKIB3_ADS

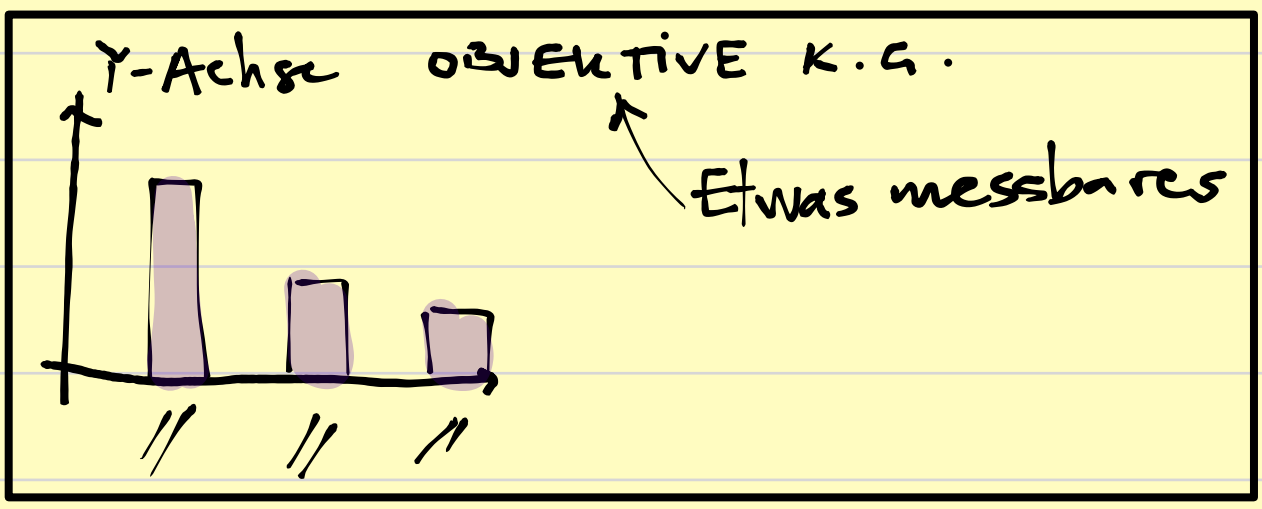


- 1 PDF
  - → 4 Blättern (VPls)
  - → CODE
- 1 x WOCHE
- Regeln.
- Letzte Sonntagsabgabe 22.11.26 23:59. 7 x Abgaben
- Mündliche Prüfung am 25.11.26



Alle Abgaben in Papierform.

Ca. 5 bis 10 Minuten. Mündliche Prüfung Inhalt sind die von Euch erstellten Dokumenten (Blätter & Code).



- SITUATIVE FÜHRUNG.

- Code
- # Erklärung

Mathematische Grundlagen

A1. Baustein & Notation

- ZAHL. $a \in \mathbb{R}$ zB: $a = 7{,}13$
- LISTE (VEKTOR). eine geordnete Liste von Zahlen

zB: $\vec{v} = [1, 3{,}7, 2{,}3, \ldots, -1{,}3]$

$v_0 \; v_1 \; v_2 \cdots v_n$ $\quad \vec{v} \neq \vec{w}$

$\vec{w} = [3{,}7, 1, 2{,}3, \ldots, -1{,}3]$

- TABELLE (MATRIX). eine rechteckige Anordnung von Zahlen.

Jede Zeile ≡ eine Beobachtung

jede Spalte ≡ ein Merkmal.

$$A = \begin{bmatrix} a_{11} & a_{21} & \cdots & a_{m1} \\ a_{12} & a_{22} & \cdots & a_{m2} \\ a_{13} & a_{23} & \cdots & a_{m3} \\ \vdots & & & \\ a_{1n} & a_{2n} & \cdots & a_{mn} \end{bmatrix}$$

→ Beobachtungen (Tage)

Merkmalen (KPIs)

Beispielen:

$$A = \begin{bmatrix} \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot \end{bmatrix}$$

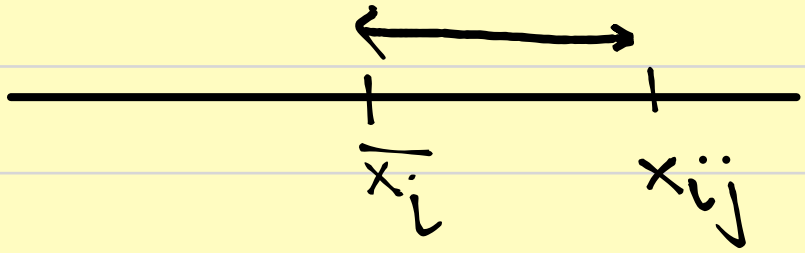
Mo
Di
Mi
Do
Fr
Sa
So

kpi (kg) | Bewegung (m) | kcal/kg | ≡

Indexierung: das Element a_{ij} bedeutet dann die Beobachtung „..j" und die Merkmal „..i"

- Mittelwert (Durchschnitt) $\bar{x}_i = \frac{1}{n}\sum_{j=1}^{n} x_{ij}$

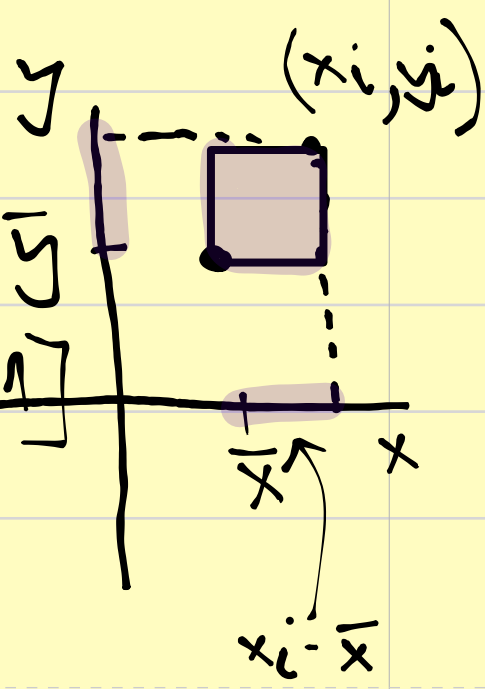
  Mittelwert Merkmal „i"
- Abweichung vom Durchschnitt: $x_{ij} - \bar{x}_i$
- Abstand zum Mittelwert ist die Abweichung vom Durchschnitt.



- Stichprobenvarianz: $VAR(x_i) = \frac{1}{n}\sum_{i=1}^{n}(x_{ij} - \bar{x}_i)^2$
- Standard Abweichung: $\sigma(x_i) = \sqrt{VAR(x_i)}$
- Co-Varianz (2 Merkmale)

$$cov(x,y) = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})$$

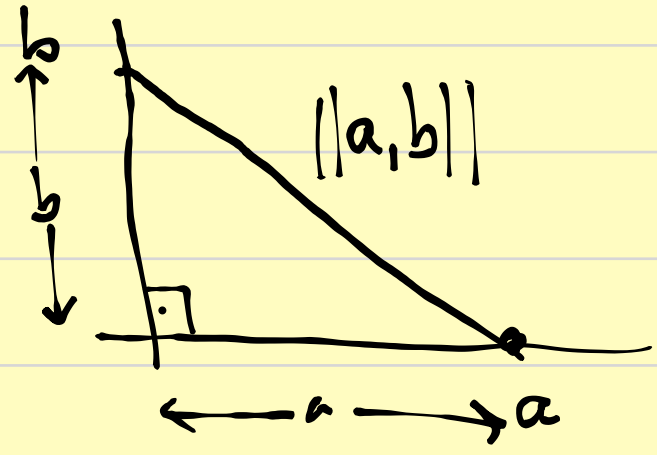
- Korrelation $CORR(x,y) = \frac{cov(x,y)}{\sigma(x)\sigma(y)} \in [-1,1]$



- Standardisierung/Normierung: $z_i = \frac{x_i - \bar{x}}{\sigma(x)}$

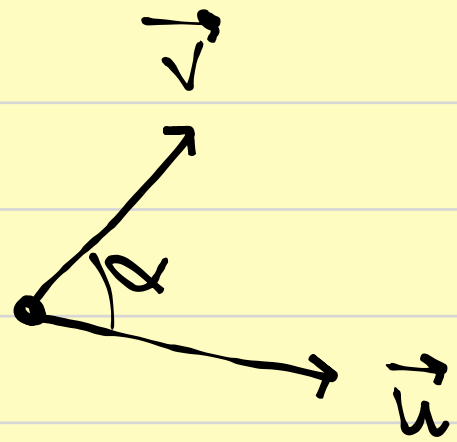
- Vektor-Länge (Euklydische Norm)

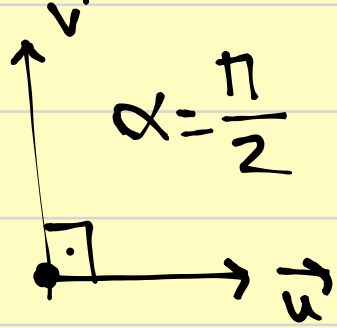
$$||a,b|| = \sqrt{a^2+b^2}$$

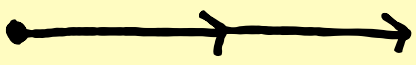


- Skalar Produkt (Innenprodukt)

$$\vec{u}\cdot\vec{v} = \sum u_j v_j = ||\vec{u}||\,||\vec{v}||\cos(\vec{u}\,\hat{\alpha}\,\vec{v})$$







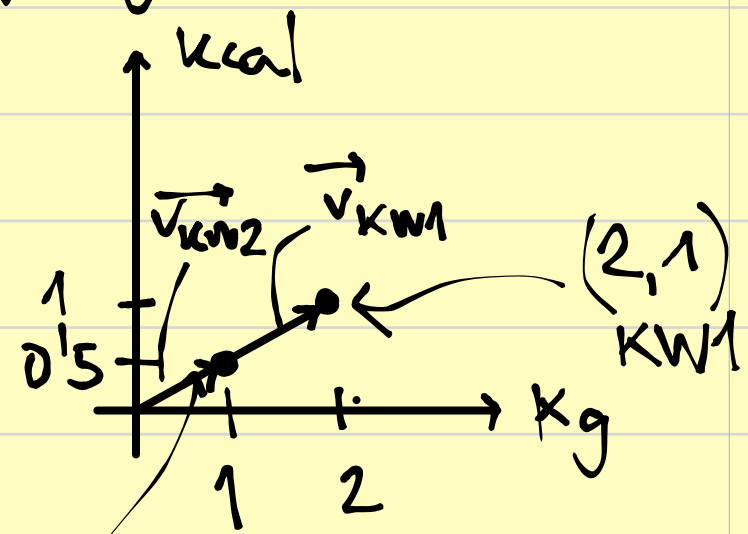
$\vec{u}\cdot\vec{v} = ||\vec{u}||\cdot||\vec{v}||$

$\vec{u}\cdot\vec{v} = 0$

Beispiel:

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 0{,}5 \end{bmatrix} \begin{matrix} KW1 \\ KW2 \end{matrix}$$

kg kcal

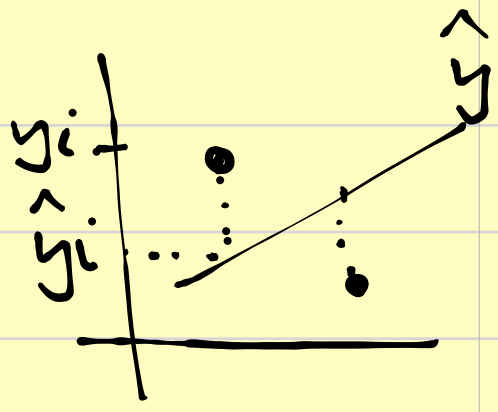


α = 0 : $\vec{v}_{KW1}\cdot\vec{v}_{KW2} = ||\vec{v}_{KW1}||\,||\vec{v}_{KW2}||\,(1,0{,}5)$ KWL

KORR : Maxima

...

- MSE Fehler.



- Linear es 1D. Modell: $\hat{y} = a + bx$
- Vorhersagefehler: $e_i = y_i - \hat{y}_i = y_i - a - bx_i$
- Quadratischer Fehler: $e_i^2 \geq 0$ (EIN PUNKT!)
- Mittlerer Quadratischer Fehler
  Mean Squared Error (MSE)

$$MSE(a,b) = \frac{1}{n}\sum_{i=1}^{n} e_i^2 = \frac{1}{n}\sum_{i=1}^{n}(y_i - a - bx_i)^2$$

- Ableitung / Gradient.

Ableitung ist die Steigung einer Funktion.
Wenn wir „a" oder „b" ein wenig verändern,
und die MSE dadurch steigt, dann ist die Veränderung
nicht in die erwünschte Richtung.

2 Variabeln:

Gradient (bei 2 Variabeln a, b) = Vektor der Ableitungen

$$\rightarrow \left[\frac{\partial MSE}{a}, \frac{\partial MSE}{b}\right]$$

· GRADIENT DESCENT : wir starten mit a, b Werte (Initialisierung), gehen in kleinen Schritten entgegen des Gradients.

$\eta \equiv$ Lernrate

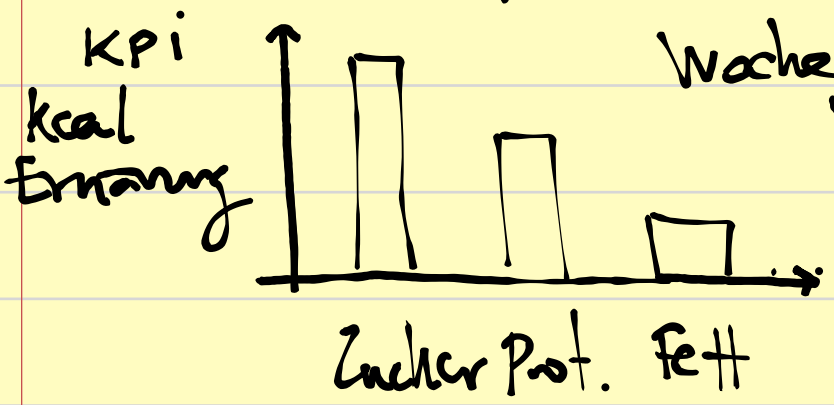
$$a \longrightarrow a - \eta \frac{\partial MSE}{\partial a}$$

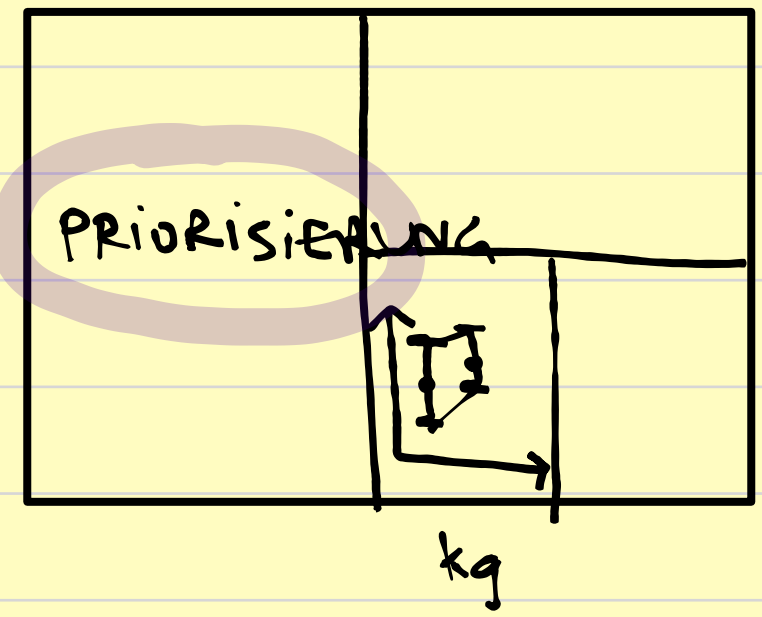
$$b \longrightarrow b - \eta \frac{\partial MSE}{\partial b}$$

(2. Semester)

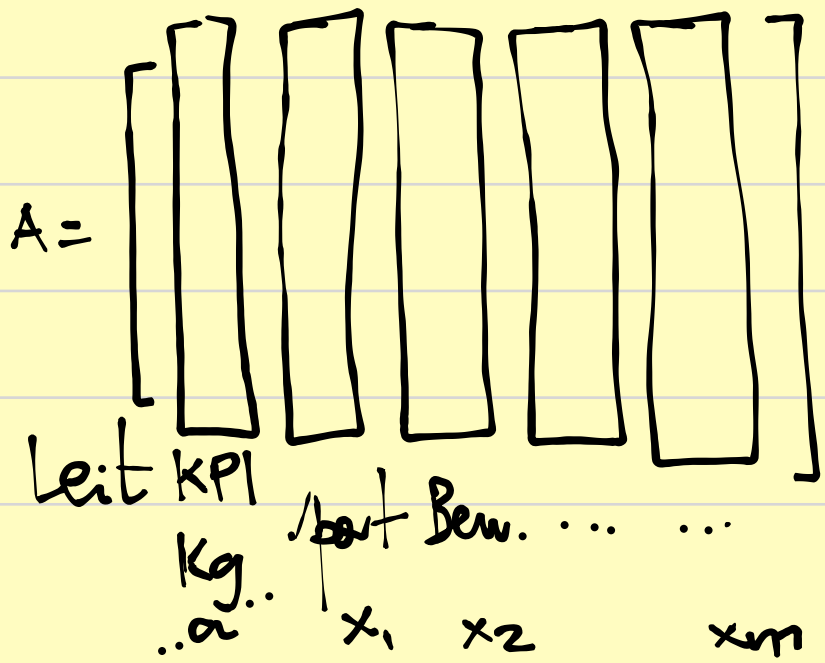
$$b = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} \qquad a = \bar{y} - b\bar{x}$$

1. PARETO (1D)





2. Mehrdimensionale PRIORISIERUNGEN

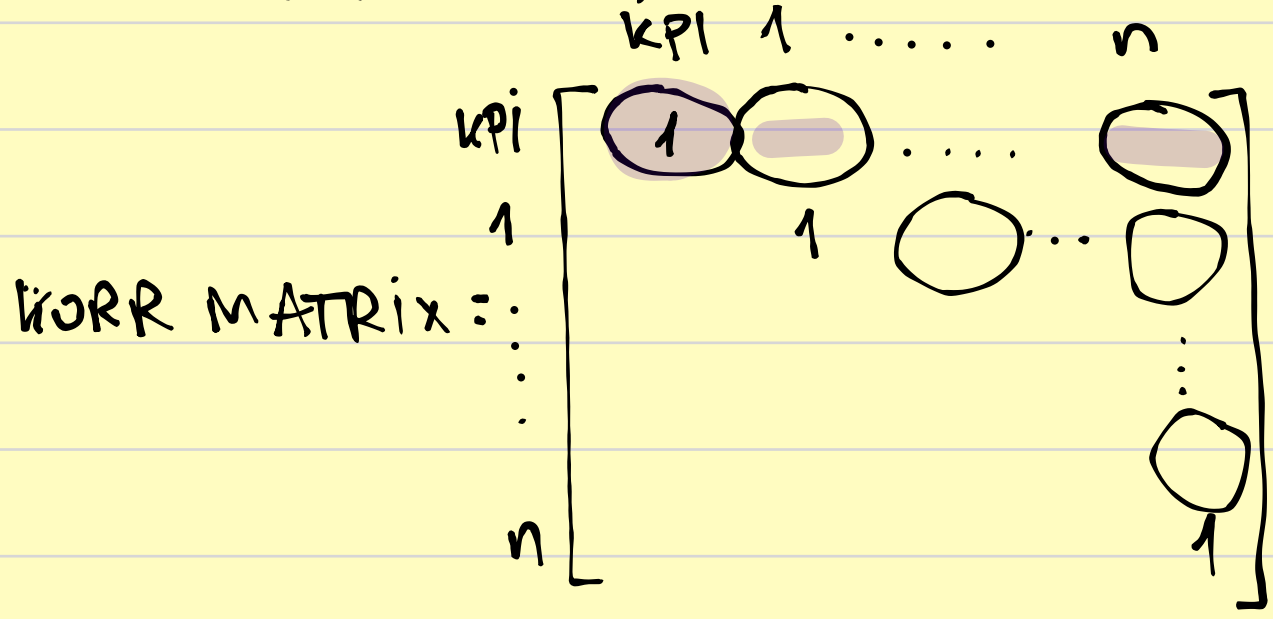


$$\hat{y} = a + w_1 x_1 + w_2 x_2 + \ldots + w_m x_m$$

2.1 Designmatrix: wir bauen aus den Daten eine Tabelle A mit „n" Zeilen (Beobachtungen) und „m" Spalten (Merkmale) und fügen links eine Spalte „a" hinzu.

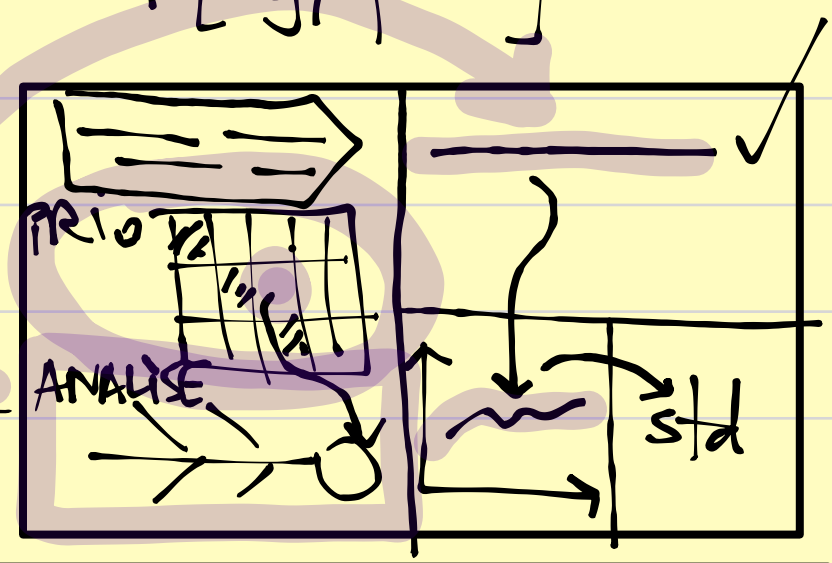
LSP: Least Square Problem: Finde $a, w_1, w_2, \dots, w_n$ die, die MSE minimieren. „Least Square Solver"

2.2 · Korrelationsmatrix



$$KORR[kg, sport] = \frac{cov(kg, sport)}{\sigma(kg)\,\sigma(sport)}$$

$$kg = \begin{bmatrix} \vdots \end{bmatrix} \quad sport = \begin{bmatrix} \vdots \end{bmatrix} \longrightarrow KORR[kg, sport]$$



1 Dimensionale Versuche

Datenvorbereitung

Begriffe: Datensatz: Tabelle mit „n" Zeilen und „m" Spalten
Beobachtungen Merkmale

- Numerische Merkmale: reelle Werte (zB: Preis, Gewicht)
- Kategorische Merkmale: endliche Ausprägungen.
  zB: Wetter: sonnig, regen, heiter, wolkig
- Ordinale Merkmale: zB Schulnoten
- Zeitstempel: Zeitpunkte, Zeiträume

Fehlende Daten:

- Darstellung: in der Regel mit einem „NA" dargestellt
- Es gibt verschiedene Arten von N.A.

☐ MCAR. Missing Completely at Random
Das fehlen der Daten hat keinen Zusammenhang mit den Daten selbst.

☐ MAR. Missing at Random
Das fehlen der Daten hängt von beobachteten Variablen ab (zB Information über Patienten wird ausgeblendet).

☐ MNAR. Missing not at Random
Das fehlen der Daten hängt mit dem fehlenden

Wert selbst zusammen.

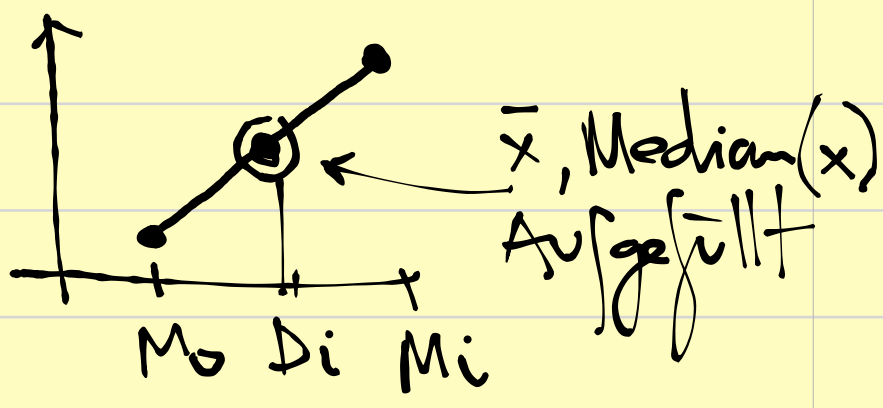
→ GOODHART'S LAW



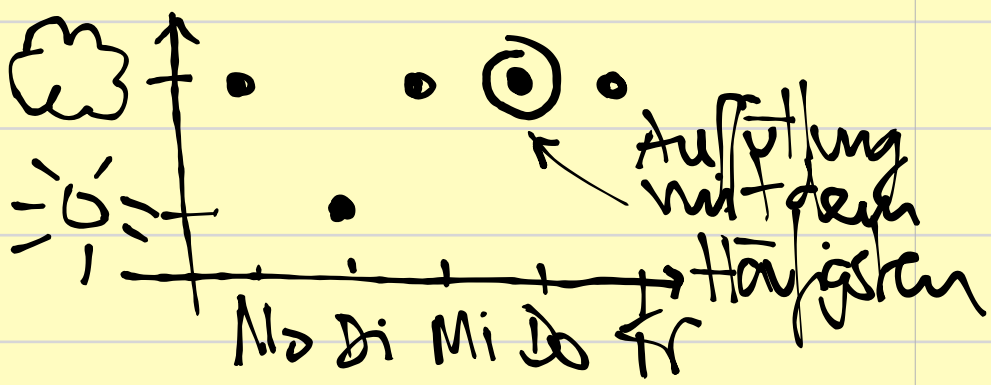
Was kann ich tun, wenn Werte fehlen?

· Imputation. (Auffüllen)

→ Numerisch



→ kategorisch



→ Fehlindikator als neue Feature, damit das Model „weiß", dass etwas gefehlt hat.

· SKALIERUNG/NORMIERUNG numerische Merkmale.

· standardisierung (z-Score): $z_i = \frac{x_i - \bar{x}}{std(x)}$

- Min-Max Normierung [0,1] $x' = \frac{x - x_{min}}{x_{max} - x_{min}}$

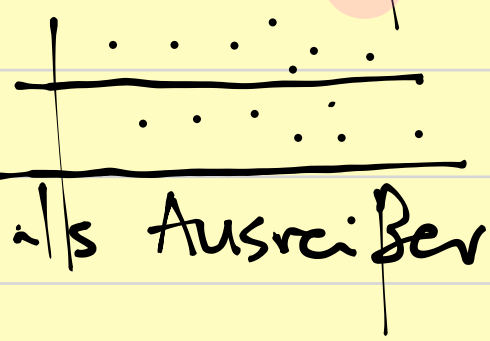
- Robuste Skalierung $x' = \frac{x - med(x)}{IQR(x)}$

  $IQR(x) = Q_{0'75} - Q_{0'25}$

  (unempfindlich gegen Ausreißer)

- Ausreißer: IQR (Regel) Was gilt als Ausreißer?

$\Delta = |Q_{0'25} - 1'5 IQR, Q_{0'75} + 1'5 IQR|$

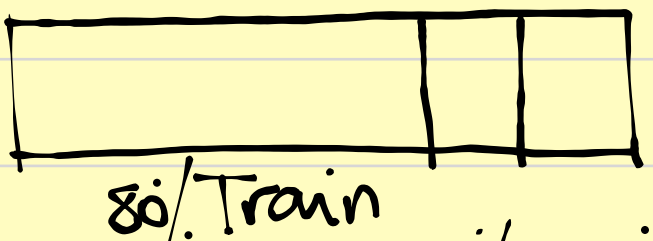


Alles außerhalb dem Interval Δ gilt als Ausreißer.

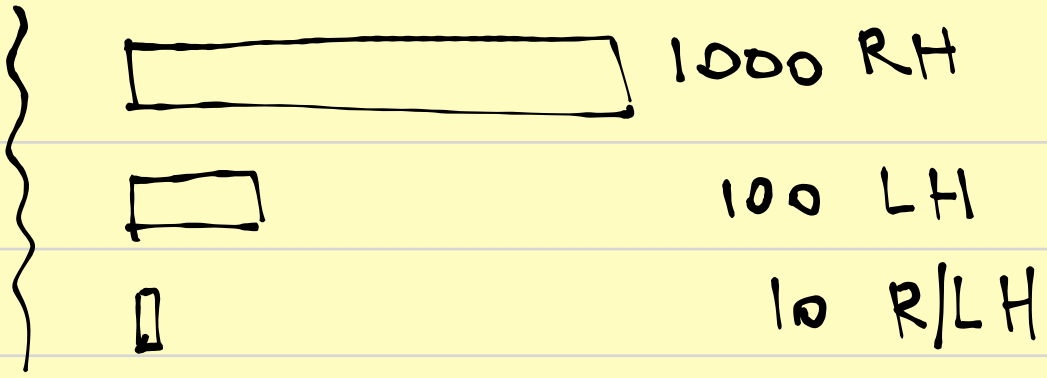
- Quantile kappen (WINSORIZING): alles was über 99% und unter 1% wird nicht berücksichtigt.

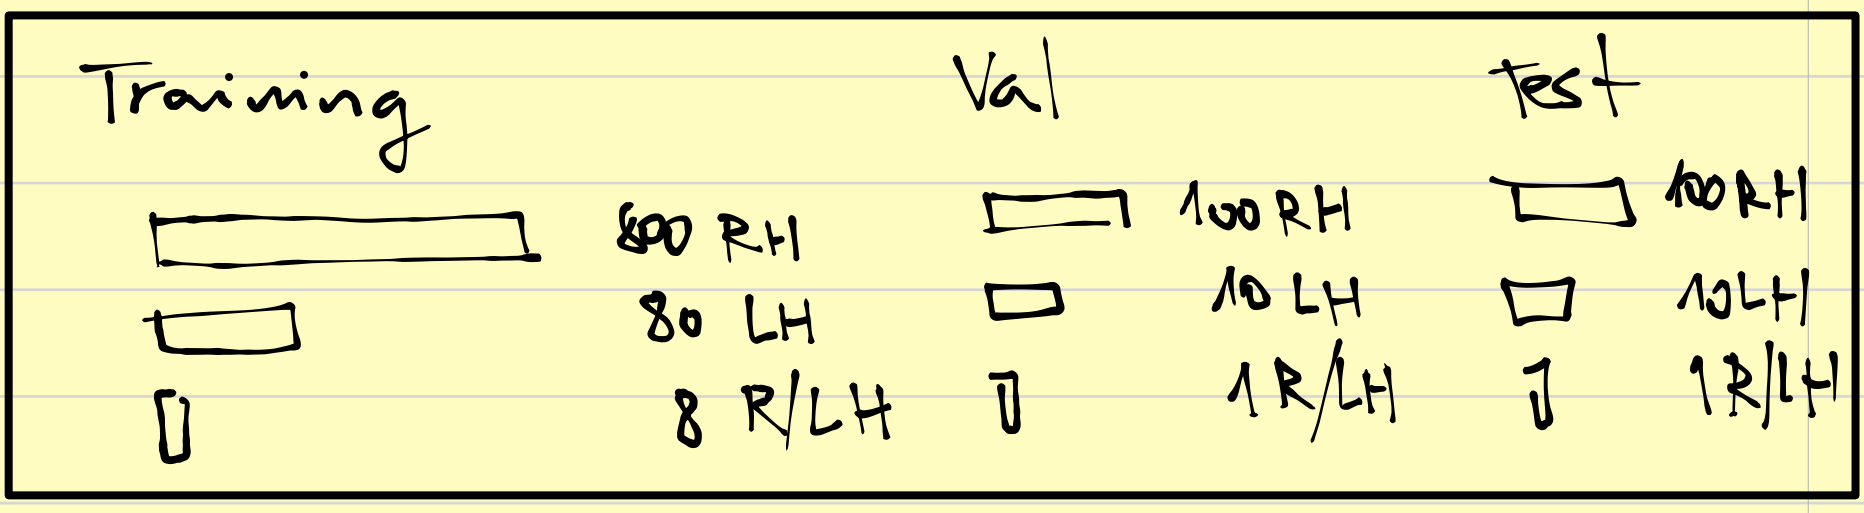
WICHTIG: kappen/schneiden von Daten NUR bei Training Bei Test/Validierung → keine Datenleckage!!

Mehrere Daten:



- Die Daten müssen ähnliche statistische Verteilung der Populationen haben: BALANCIERUNG.


1000 RH
100 LH
10 R/LH


Training
800 RH
80 LH
8 R/LH
Val
100 RH
10 LH
1 R/LH
Test
100 RH
10 LH
1 R/LH