20261021 AKIB3

1. Datenvorbereitung
2. Process auswahl + KPI-Erstellen
3. Deskriptive Statistik und Matrix
4. Visualisierung + 1D Pareto
5. Regression + Mehrdimensionales KPI-Priorisieren

1 Datenvorbereitung

Notebook 2 : M0

⇒ Erster schritt : Datensats splitten:
Train (75%)
Test (25%)

In Notebook 2 : M4

⇒ Danach können wir statistik und andere machen!

- Fehlender werte Behandeln; Imputation!
  Notebook 2 - M5
  ⇒ Entweder Mean (Mittelwert) oder Median verwenden

- Ausreißer Behandeln — "Winsorizing", "Klippen"
  Notebook 2 - M8 (Beispiel Class)
  clipper = Q... (...)
  clipper.fit(X_train) → lernt das
  [clipper.Transform(X_train)
  clippe.transform(X_test)]

* Data Leakage Warning: Compute statistics ONLY on Train data!

2. KPI - Erzeugung

KPIs können durch verschieden Operationen erzeugt werden

Beispiel: Price pro m^2

```
df['price'] / df["area_m2"]
```

1. Verhältniss & Effizienz ⇒ Division (A/B)
2. Interaktions - Indizes ⇒ Multiplication:

   Bsp ⇒ sleep hours × sleep quality
   = Recovery

3. Volumina & Salden (Addition oder Subtraction)

   Bsp ⇒ Fett + Prot. + Zucker = kcal
   ↑ KPI

3. Deskriptive Stastistik und Korrelationsmatrix

Notebook 1 - M0

- Mittelwert und varianz $\sigma^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$
- z-Transformation (Normierung) $z_i = \frac{(x_i - \bar{x})}{\sigma(x)}$

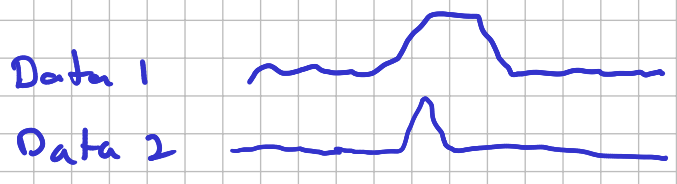
Notebook 1 - M6

- Korrelationsmatrix

4. Visulisierung

- 1D Pareto (see Hf's lecture)
- Matrix Heatmap Notebook 1 - M6

Correlation Heatmap



⇒ Korrelation ist immer $\in [-1, 1]$

	D1	D2
D1	-	=
D	..	..

- Modell Anpassung – Scatterplot mit 1D Regression

$$\hat{y} = bx + a$$

Notebook 1 - M1

5. Multi-D Regression, MSE & Priorisieren

Mehrdimensionales Modell & MSE

Notebook 1 - M4

=> Durch Gradient-Decent MSE minimieren

=> Mehrdimensionale Priorisieren:

$$\hat{y} = a + w_1 x_1 + w_2 x_2$$

Notebook 1 - M4

Praktische Übung

⇒ Student Productivity Datensatz

Teil 1: Datenvorbereitung

- Importieren sie den Datensatz und bereiten sie die Daten so vor, dass verzerrungen vermeiden und kein Data Leakage auftritt.

  - CSV importieren in ein Pandas Dataframe.
  - Train/Test Split 20000 Datenzeilen -> 75/25
  * Zielspalte: productivity_score
  - Winsorizing (Grenzwerte Kappen)
    → Bestimmen die 1%- und 99%-Quantile ausschließlich auf dem Train-split !!!
    → Clippen sie Extremwerte auf Train und Test mit die Grenzen

Teil 2: KPI-Erstellung

KPI 1 - Total Screen Time (Addition)

phon_usage_hours + social_media_usage + youtube_usage + gaming_hours = kpi_total_screen_time

KPI 2 - Study-to-Distraction Ratio (Verhältniss)

Verhältniss von Lernzeit und Ablenkung

kpi_study_ratio = study_hours / (kpi_total_screen_time + 0,1)

KPI 3 - Academic Engagement Index (Multiplikation):

kpi_engagement = attendance_percentage x assignments_completed

KPI 4 - Rest-to-Stress Balance (Subtraktion):

kpi_rest_balance = sleep_hours - stress_level

Teil 3: Deskriptive Statistik und z-Standardisierung

⚠ Wichtig: Nur auf Train split !!!

- Mittelwert und Standardabweichung μ & σ
  → Für jede KPI berechnen!

- z-Transformation: Transformieren Sie den KPIs in z-scores:

$$z = (x - \mu) / \sigma .$$

  Nutzen sie die Train-Parameter μ_{Train} and σ_{Train} zur Skalierung beider splits.

- Korrelationsmatrix: Berechnen Sie die Pearson-Correlation Matrix über die 4 standardisierten KPIs im Train-set, um Überschneidungen festzulegen.

Teil 4: Visualisierung - Pareto & Correlation Heatmap

- 1D Pareto-Priorisierung:

  Erstellen Sie ein Pareto-Diagram für den KPI kpi_total_screen_time. Sortieren die 4 Komponenten (Phone, Social Media, YT, Gaming) absteigend nach ihrem durchschnittsanteil und stellen die Kumilierte Prozentkurve dar

- Komponenten-Ranking: Identifizieren Sie die Top-80% Haupttreiber der Bildschirmzeit.

- Matrix Heatmap:

  Visualisieren die in Teil 3 berechnete Korrelationsmatrix als farbcodierte Heatmap ⇒ **See Notebook 1 - M6**

Teil 5: Mehrdimensionale Regression & KPI Priorisierung

Modilieren Sie die Produktivität (productivity_score) anhand die 4 z-standardisierten KPIs

- **Modell-Training:**

  Trainieren sie eine Mehrdimensionale lineare Regression

  $\hat{y} = a + w_1 x_1 + w_2 x_2 + w_3 x_3 + w_4 x_4$

  zur Vorhersage des Target-Features productivity_score.

- **Evaluierung (MSE):**

  Berechnen Sie den MSE sowohl auf dem Train-split als auch auf dem Test-split.

- **Gewichtungs-Ranking (Priorisierung) !**

* See Notebook 1 - M4