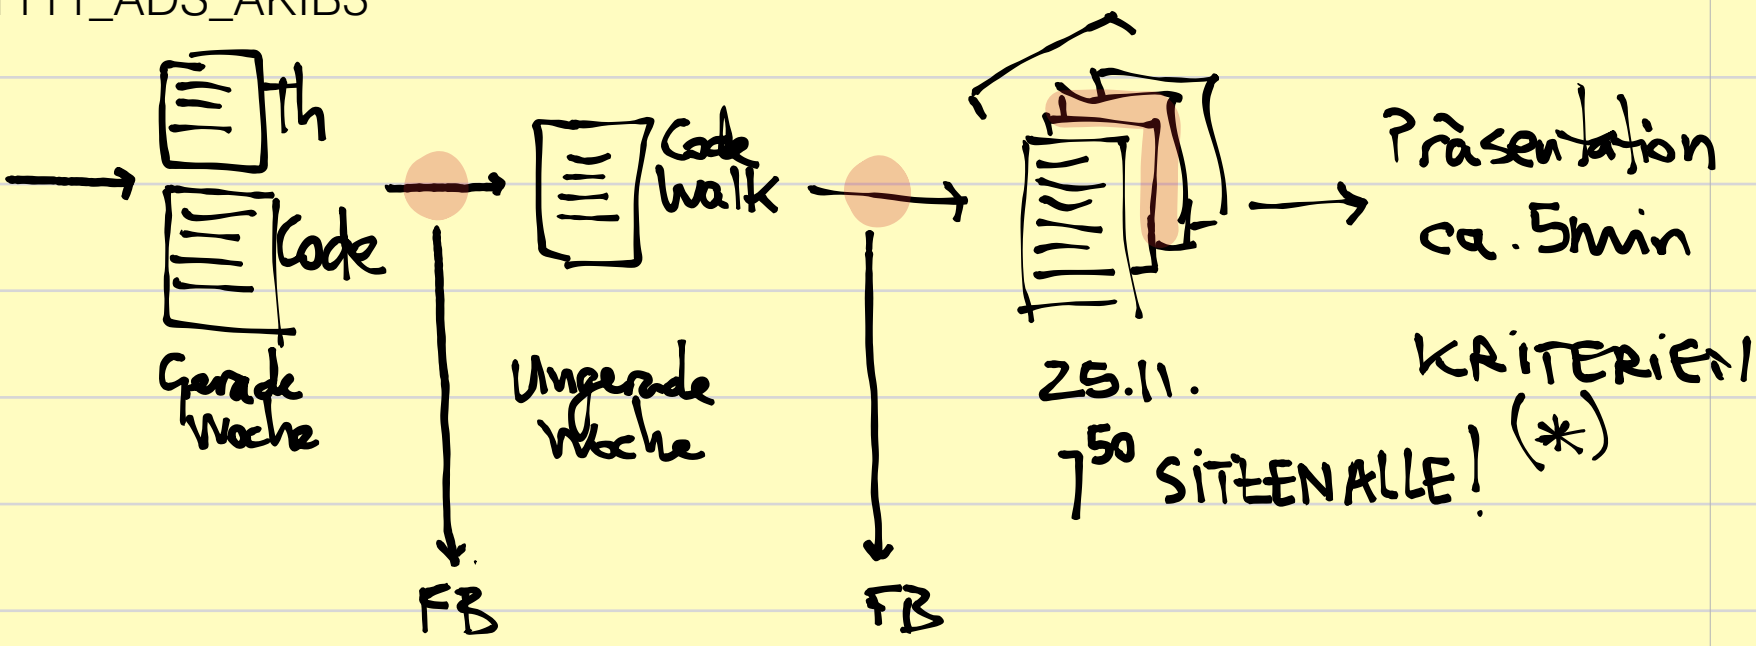
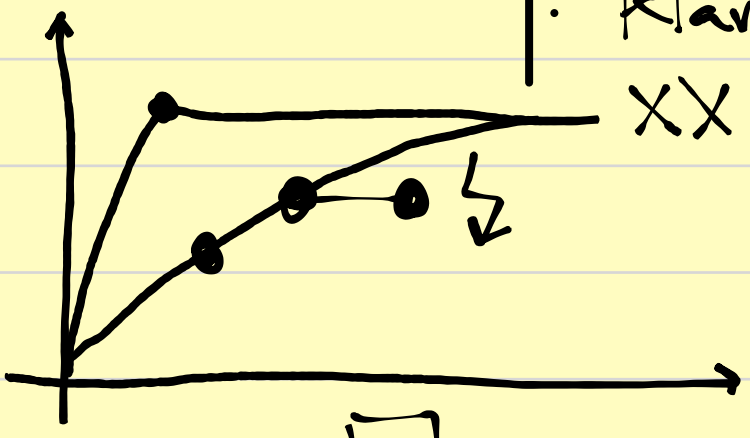
20261111_ADS_AKIB3

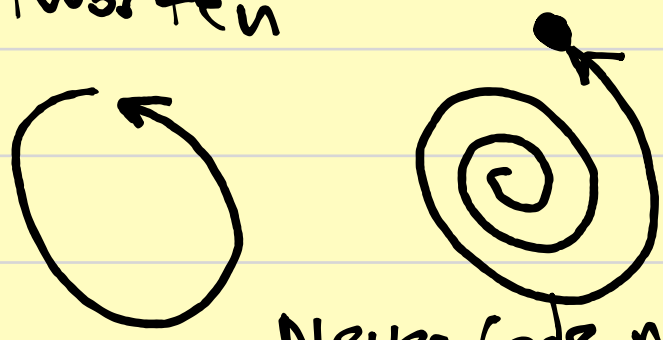



KRITERIEN (*).

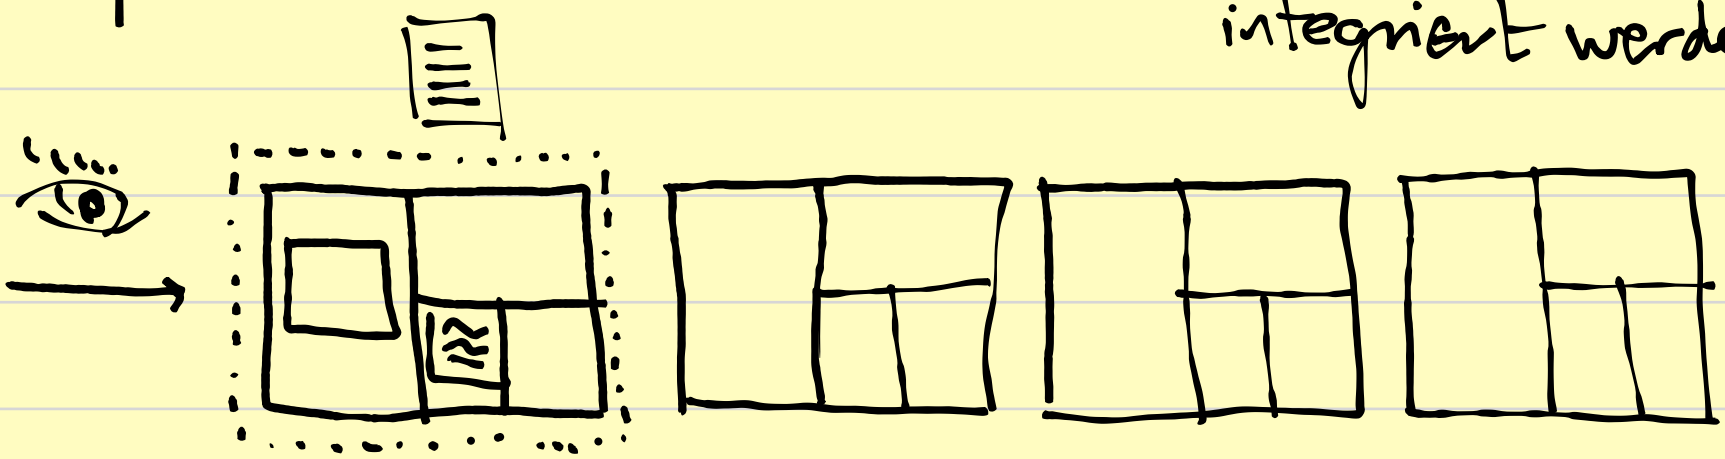
NOTE

- Technisches Verständnis
- Warum eine/andere Methodenauswahl.
- Korrekte Interpretation
- Klare Antworten



Neuer Code muss! integriert werden.



## KLASSIFIKATION MIT WAHRSCHEINLICHKEITEN (W)

Wir lernen wie man mit W. schätzt, daraus Entscheidungen abzuleiten, Schwellenwerte wählt, Modelle fair bewertet, und nicht lineare Entscheidungsgrenzen vergleicht.

1. Aufgabe & Datenbild

· Wir betrachten eine binäre Klassifikation {0,1} {Ja, Nein} ...

· Eingaben sind Merkmale in einer Tabelle, jedes Beispiel gehört genau zu einer Klasse.

· Ziel ist eine Funktion die für jedes Beispiel eine W für Klasse „0" / „1" liefert.

2. LOGISTISCHE REGRESSION ALS W-MODELL

· Wir modellieren die s.g. LOGIT-FUNKTION als lineare Funktion der Merkmale

· Sei $\Pi(x)$ die W für Klasse 1:

$$\log\left[\frac{\Pi(x)}{1-\Pi(x)}\right] = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n \qquad (1)$$

· Das Logarithmus der Quotient $\frac{P(1)}{P(0)} = \frac{\Pi(x)}{1-\Pi(x)}$ wird als lineare Kombination der Merkmale dargestellt.

· Daraus entsteht die s.g. SIGMOID-FUNKTION

$$\frac{\Pi(x)}{1-\Pi(x)} = e^{\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n} \rightarrow \boxed{\Pi(x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}}}$$

· Die Schätzung der Gewichte $\beta_i$ erfolgt durch Maximierung der Wahrscheinlichkeit (Likelihood):

$$\mathcal{L}(\beta_0, \beta_1, \dots, \beta_n) = \prod_{i=1}^{n} \pi(x_i)^{y_i} \left(1-\pi(x_i)\right)^{1-y_i}$$

· Wenn die Merkmale normiert sind, steht $\exp(\beta_j)$ für den Faktor, um den sich die Chancen auf Klasse 1 ändern, wenn $x_j$ um eine Standard Abweichung steigt, während andere Merkmale konstant bleiben.

Beispiel: Bestehen/nicht bestehen.

| $x_1$ | $x_2$ | .... | $x_n$ | Entscheidung (1 / 0) |
|---|---|---|---|---|
| kw | = | = | = | 1 |
| kw | = | = | = | 0 |
| ⋮ | | | | |

W bestehen $p(1) = \pi(x_i)$
W nicht best. $p(0) = 1-\pi(x_i)$

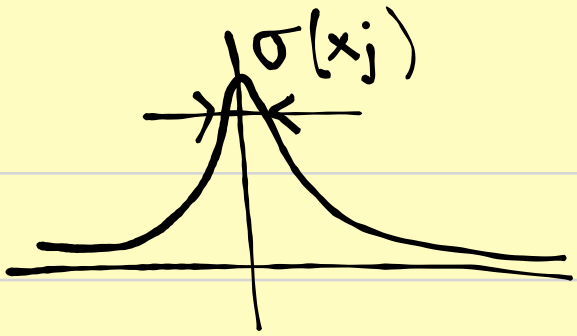
$$\log\left[\frac{\pi(x_i)}{1-\pi(x_i)}\right] = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$$

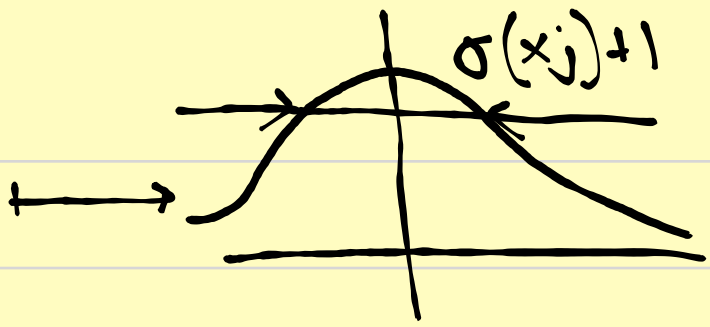
Wir suchen die $\beta_j$ Gewichte um die Regression/Prognose bei einer neuen Woche vorherzusehen.

Wie muss sich der Prozess verhalten um zu bestehen?

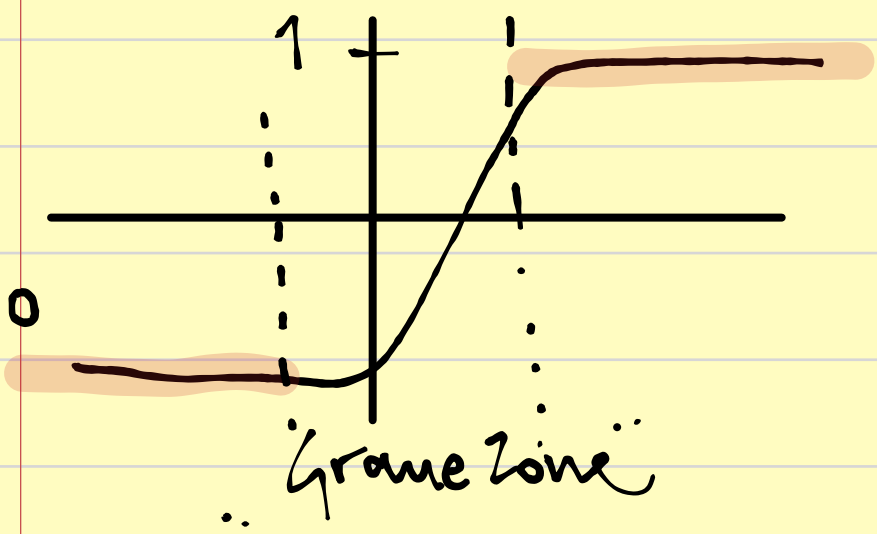
Wenn wir die $\beta$s kennen, kennen wir das Verhalten des Prozesses.

Bedeutung von $\beta_j$: $e^{\beta_j}$ erklärt wie verändert sich $\pi(x_j)$ wenn $\sigma(x_j) \longrightarrow \sigma(x_j)+1$ ($x_j$ ist normiert).



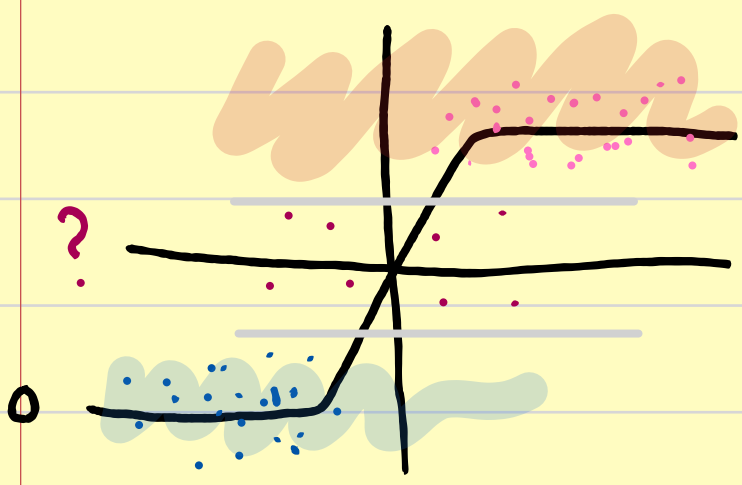




$\pi(x_j)$



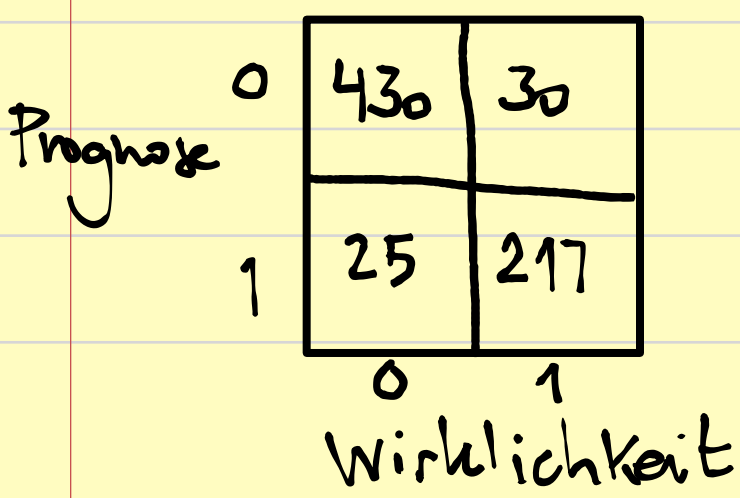

3. WAHL des SCHWELLENWERTES.

- Ein Vorhersage ist zunächst eine W.
- Eine Klassenzuordnung entsteht erst nach Festlegung des Schwellenwertes.
  Standard ist 0'5.




1 Klasse 1
0'5 ← Schwellenwerte sind eine Designentscheidung von Modell.
0'5
Klasse 0

4. Verwechslungsmatrix & Grund-Metriken.



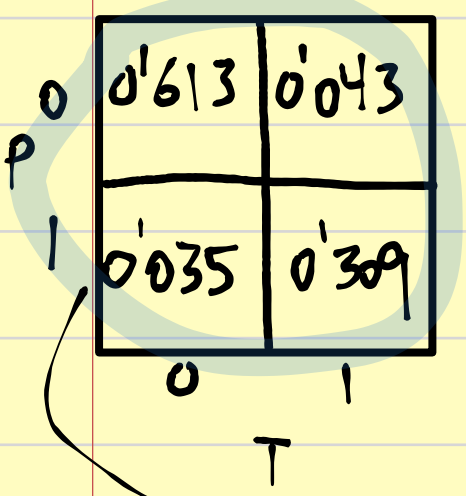

4 Felder: TRUE POSITIV. TP
FALSCH POSITIV. FP
TRUE NEGATIV TN
FALSCH NEGATIV FN

Hiv Test: 702 Probanden: $\sum 430+30+25+217 = 702$

1. Positiv.
0. Negativ.

**TP** bedeutet: ich bin infiziert und wurde als infiziert erkannt.

$$TP = \sum \Pi \{\hat{y}=1, y=1\} = \frac{217}{702} = 0'309$$




**TN** bedeutet: ich bin nicht infiziert und wurde als nicht infiziert erkannt.

$$TN = \sum \Pi \{\hat{y}=0, y=0\} = \frac{430}{702} = 0'613$$

**FP** bedeutet: ich bin nicht infiziert und wurde als infiziert erkannt.

$$FP = \sum \Pi \{\hat{y}=1, y=0\} = \frac{25}{702} = 0'035$$

↳ **FN** bedeutet: ich bin infiziert und wurde als nicht infiziert erkannt.

$$FN = \sum \Pi \{\hat{y}=0, y=1\} = \frac{30}{702} = 0'043$$

- **TREFFERGENAUIGKEIT**. Anteil der korrekten Vorhersagen

$$TG = \frac{TP+TN}{TP+TN+FP+FN}$$

- **PRÄZISION**. Anteil wahres positive Falle unter allen als positiv vorhergesagten Fällen.

$$P = \frac{TP}{TP+FP}$$

- **TREFFERQUOTE**: Anteil wahre positive Fälle, die korrekt als positiv erkannt werden.

$$TQ = \frac{TP}{TP+FN}$$

- **F1-WERT**: Mittel aus Präzision & Trefferquote.

$$F1 = \frac{2 \cdot P \cdot TQ}{P+TQ}$$

- **SPEZIFITÄT**:

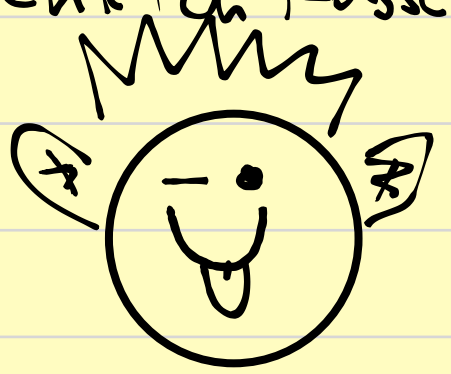
$$SP = \frac{TN}{TN+TP}$$

- **FEHLERALARMQUOTE**

$$FA = \frac{FP}{FP+TN}$$

- **BRIER-WERT**: mittlere quadratische Abweichung zw. vorhergesagten W & den beobachteten Klassen. Misst die Güte der W selbst.

$$BRIER = \frac{1}{n} \sum_{i=1}^{n} (\hat{\pi}_i - y_i)^2$$



---

## MODELLAUSWAHL & REGULARISIERUNG

Wir wollen die wahre Vorhersagegüte realistisch einschätzen, Über-Anpassungen vermeiden und die Modellkomplexität bewusst steuern.

Wir nutzen Lern- & Validierungskurven, k-fache Kreuz-validierung und verschaltete Kreuzvalidierung.

INTUITION: Nicht das Modell, das Training am besten auswendig kann, gewinnt – sondern das, das neue Daten gut trifft.

## 1. PROBLEMRAHMEN

Datenmodell $\bar{y} = f^*(\bar{x}) + \varepsilon \quad E(\bar{x}) = 0 \quad VAR(\bar{x}) = \sigma^2$

Prädiktor: Aus Trainingsdaten $D$ lernen wir $\hat{f}(D)$

$$MSE_{test} = E\left[\left(y - \hat{f}_D(\bar{x})\right)^2\right]$$

INTUITION: wie sehr verfehlt unser Modell im Durchschnitt bei neuen Fällen?

## 2. BIAS-VARIANZ ZERLEGUNG.

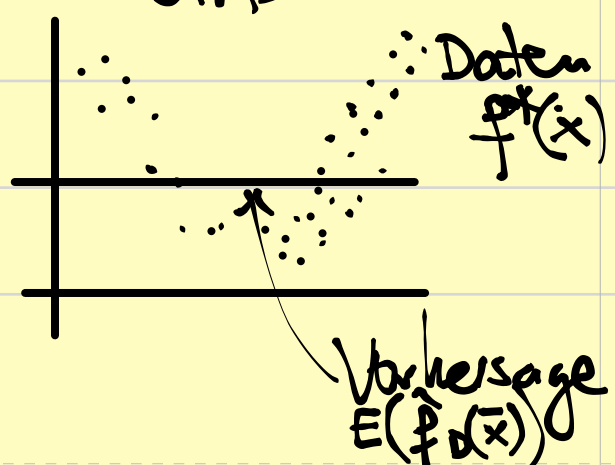
$$\text{Zerlegung: } E\left[\left(y - \hat{f}_D(\bar{x})\right)^2 \mid \bar{x}\right] = \sigma^2 + \left[E\left(\hat{f}_D(\bar{x}) - f^*(\bar{x})\right)\right]^2 + VAR\left(\hat{f}_D(\bar{x})\right)$$

Rauschen — BIAS — VARIANZ

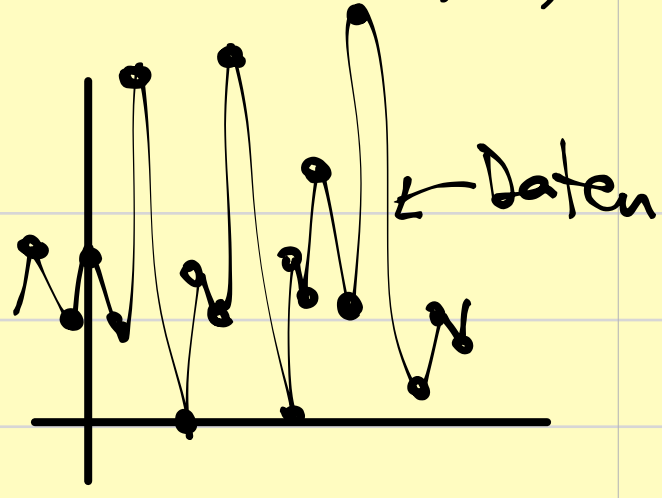
Intuition:

- BIAS: systematischer Fehler

Das Modell ist zu einfach.



- VARIANZ: Empfindlichkeit gegenüber der Stichprobe.
  Das Modell ist zu zappelig.




Ein Modell mit extrem vielen Zacken führt zu einem zackigen Fit, der jeden Punkt treffen will.

Hebel bei der Modellierung: KOMPLEXITÄTSERHÖHUNG: BIAS↓, VARIANZ↑
KOMPLEXITÄTSREDUKTION: BIAS↑ VARIANZ↓

Sweet Spot liegt da wo $BIAS^2 + VAR + RAUSCHEN$ minimal ist.

3. REGULARISIERUNG. kontrollierte Einfachheit.
RIDGE / LASSO.

Ausgangspunkt $\min \frac{1}{n} \|\bar{y} - \bar{X}\bar{w}\|_2^2$

- RIDGE-REGRESSION (L2-Strafe)
Alle Gewichte werden gleichmäßig in Richtung NULL gezogen. („Gummiband")
Gut bei Multilinearität und wenn alle Merkmale etwas beitragen.

$$\min_w \frac{1}{n} \|\bar{y} - \bar{X}\bar{w}\|_2^2 \quad ; \quad \hat{w}_\lambda = \left[\bar{X}^T \bar{X} + n\lambda \bar{\Gamma}\right]^{-1} \bar{X}^T \bar{y}$$

· LASSO · (L1-Strafe)

Viele Gewichte werden genau auf NULL gedrückt („Sparsamkeit"). Automatische Merkmalauswahl.

$$\min_w \frac{1}{n} \|\bar{y} - \bar{X}\bar{w}\|_2^2 + \lambda \bar{w}$$

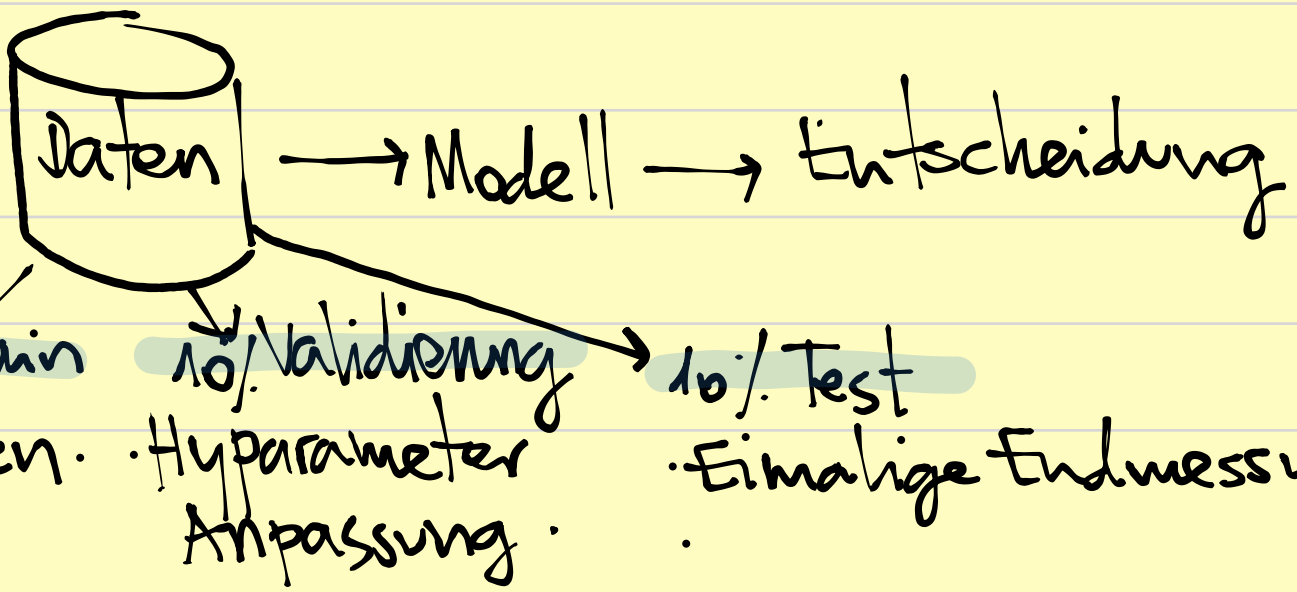
Intuition: Ridge (L2) bei vielen schwach-nützlichen Merkmalen.

Lasso (L1) wenn nur wenige wirklich relevant sind.

ERWEITERUNG: „ELASTIC-NET" kombiniert L1+L2
robust bei stark korrelierten Merkmalen.

λ ist der „KOMPLEXITÄTSKNOPF"
- λ klein: flexibel (Varianz↑)
- λ groß: glatt (Bias↑)

4. TRAIN/VALIDATION/TEST bzw. K-fache Kreuzvalidierung



· k-fache Kreuzvalidierung: die Daten werden in k Gruppen/Falten getrennt, wiederholt auf k-1 Falten trainiert

Cross-Validation (CV). Hier verringern wir Zufallsschwankungen. Liefert stabile Schätzungen und nutzt Daten effizienter.

Checkliste: 1) Daten in Train/Validation/Test teilen
2) Pipeline bauen
3) Lernkurve prüfen.
4) Validierung der Kurve durch k-fold CV.
5) Endmodell auf Train fitten und 1× Test auswerten.
6) Bericht mit Zahlen & Plots erstellen. Entscheidung begründen BIAS/VAR.